

Machine Learning Final Proposal

Small Data Training for Medical Images

NTU_b05901009_易昀競選總部

B05901009 高瑋聰

B05901022 許睿洋

B05901034 劉奎元

1. Problem Study

(1) CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning

Link: <https://arxiv.org/abs/1711.05225>

使用ImageNet pre-trained的DenseNet-121, 採用Adam(標準beta值, lr=1e-4)與小batch size(16), 並且使用learning rate decay。圖片放入時使用ImageNet的mean及variance做normalization, 並且縮小成224x224, 再加入horizontal flip當data augmentation。

(2) Deep Clustering for Unsupervised Learning of Visual Features

Link: <https://arxiv.org/abs/1807.05520>

Usage : faiss : <https://github.com/facebookresearch/faiss>

使用DNN抽取feature, 再利用k-means分群當作label, 並且交替訓練k-means與DNN, 須注意兩個問題: 1.empty cluster 2. trivial parameterization。第一個問題的解決方法為暫時使用一個non-empty cluster的中心位置在加入一些noise當empty cluster新的中心。而第二個問題發生的情況為data unbalanced時, 容易造成將data全分為同一類的情況, 解決方法為從data中uniform sample一些data出來當training data。

k-means的部分可以使用faiss的api, 可利用GPU加速運算。

(3) Densely Connected Convolutional Networks

Link: <https://arxiv.org/abs/1608.06993>

採用了與ResNet相似的想法, 差別在於Dense Block中每一層convolution會連接到block內前面每一個convolution的輸出, 來達到重複利用feature與改善gradient vanish的問題。此外中間採用了batch normalization與network in network的1x1 convolution, 來控制channel數量(減少參數)與down sampling。output層則和ResNet一樣採用了global average pooling。

(4) Data Augmentation Generative Adversarial Networks

Link: <https://arxiv.org/abs/1711.04340>

DAGAN結合U-Net與ResNet作generator, 並使用DenseNet作為classifier。generator方面另外還以skip connection連接層與層之間及兩個model的相對應層。classifier則在DenseNet中以layer normalization取代batch normalization以符合WGAN的Objective function。generator的訓練方向則為最小化與原資料的Wasserstein distance。藉由DAGAN, 可以補足傳統data augmentation只能在很有限的方向進行變化的問題, 直接由資料找出可行的變化方向, 有效的幫助少量資料進行訓練。

(5) Augmented Cycle GAN

Link: <https://arxiv.org/pdf/1802.10151.pdf>

舊有的Cycle GAN因model特性，僅限於one-to-one的domain mapping，也較難以實現差異較大的domain mapping(e.g. class to image)，而augmented cycle GAN加入latent variable以及encoder，以幫助object在domain轉換時loss的資訊能較容易還原(否則原本的Cycle GAN只能使用object本身來還原)，也因此種特性，augmented Cycle GAN較能夠達成class to image的轉換。在此次task中，希望能運用這種功能來達到data augmentation與增加data的效果。

(6) Squeeze-and-Excitation Networks

Link: <https://arxiv.org/abs/1709.01507>

藉由兩個新加入的操作(Squeeze和Excitation)所組成之SE Block插入或替換原先ResNet的Convolution Block，以提高準確度。而能提高準確度之操作之原因為每個channel可藉由Squeeze和Excitation而有各自之比重，而非傳統CNN(如Inception, ResNet)將全部Channel同時進行訓練，除此之外，SE Block也使用特殊設計的Fully Connected層處理，使此Block能對非線性關係有更好的擬合。

2. Proposed Method

本次我們希望實做的model大致可分兩個部份：

(1) supervised(fine-tune)

我們希望嘗試DenseNet-121與Squeeze-excitationNet兩種根據ImageNet Dataset來pre-train的model，我們將input image用RandomResizeCrop縮小成224x224，再放入pre-train model，並且將最後一層改成output 14個值並且經過sigmoid(因此次task為multi-label classification)。optimizer的設定則參考CheXNet的設定使用lr=1e-4與weight decay，也會加入常見的数据 augmentation方法來防止overfitting。這部份將採取fine-tune的方式，比較要避免的是overfitting的問題。

(2) unsupervised

這部份有很多方法值得嘗試，可能會採取多個方法並行的方式。

- 我們考慮使用augmented Cycle GAN，希望可以利用這次的training data來訓練GAN並且產生更多data與label，此方法的困難為GAN要產生大張的圖片並不容易，且產生的label也可能有誤。
- 第二個方法是使用DeepCluster來對unlabeled data分類並給予label，此方法會需要用到faiss的api。困難處在於CNN與k-means model訓練的平衡程度與k-means model是否產生trivial solution，此外faiss對不同gpu的支援也略有差異。
- 第三個方法是使用基本的Auto-Encoder，利用unlabel data來訓練，之後將encoder部份當成feature extractor加入原本的model中，和supervised方法的model一起抽取feature在放入classifier得到結果。Auto-Encoder有許多種變化版本，可能需要實做後比較他們的表現。
- 第四個方法是使用DAGAN的方式產生新的資料以投入訓練。這個方法的好處在於可以有效的描繪出data manifold以增進學習的結果，可能產生比CheXNet中使用的RandomResizeCrop及HorizontalFlip還要好的效果；難處則在於GAN的訓練有相當的難度，也可能產出有誤的資料。

我們最後的model會合併兩種方法的feature extractor，並放入最後的classifier當作output。